



**Politecnico
di Torino**

Analisi del dataset di Istanbul Stock Exchange

Alessandra Marina Saldana Boy

Matricola 321750

Corso: *Matematica per l'intelligenza artificiale* (02UTJMQ)

Indice

1	Il Dataset e il Pre-processing	2
1.1	Descrizione dei dati e obiettivo	2
1.2	Analisi della Correlazione	2
1.3	Split dei dati e Scaling	4
2	Riduzione della Dimensionalità	4
2.1	Principal Component Analysis (PCA)	4
2.1.1	Formulazione Matematica del Problema di Ottimizzazione	4
2.1.2	Risoluzione tramite Moltiplicatori di Lagrange	5
2.1.3	Connessione con la Decomposizione ai Valori Singolari (SVD)	6
2.1.4	Analisi Empirica dei Risultati della PCA sul Dataset Finanziario	7
3	Modelli di Classificazione Supervisionata	9
3.1	Metodologia di Valutazione e Metriche d'Errore	9
3.2	k-Nearest Neighbors (k-NN)	10
3.2.1	Formulazione Matematica della Regola di Decisione	10
3.2.2	Risultati Sperimentali e Analisi Comparativa degli Spazi	10
3.3	Linear Discriminant Analysis (LDA)	11
3.3.1	Formulazione Bayesiana sotto Omoschedasticità	11
3.3.2	Analisi Empirica dei Risultati dell'LDA	11
3.4	SVM Non Lineari	12
3.4.1	Formulazione Primale a Soft Margin	12
3.4.2	Derivazione del Problema Duale e Condizioni KKT	12
3.4.3	Il "Kernel Trick" e gli Spazi di Hilbert a Nucleo Riproduttore (RKHS)	14
3.4.4	Analisi dei Risultati Empirici sul Dataset Finanziario	14
3.5	Multi-Layer Perceptron (MLP)	16
3.5.1	Architettura e Propagazione in Avanti (Feed-Forward)	16
3.5.2	Algoritmo di Back-Propagation e Ottimizzazione Adam	16
3.5.3	Risultati Sperimentali e Analisi Comparativa	17
4	Conclusioni e Sviluppi Futuri	19
4.1	Sintesi Comparativa dei Risultati Empirici	19
4.2	Verifiche delle Equivalenze Algebriche e Rigore Teorico	19
4.3	Analisi Geometrica e Macroeconomica dell'Asimmetria delle Predizioni	20
4.4	Violazione dell'Ipotesi I.I.D. e Limitazioni dei Modelli Spaziali	20
4.5	Sviluppi Futuri	21

1 Il Dataset e il Pre-processing

1.1 Descrizione dei dati e obiettivo

Il dataset preso in esame per questo elaborato, denominato *data_akbilgic*, contiene i rendimenti finanziari giornalieri di alcuni dei principali indici di borsa mondiali. Le osservazioni temporali raccolte coprono un lasso di tempo che va da gennaio 2009 a febbraio 2011, riflettendo le dinamiche del mercato globale a seguito di una fase di crisi economica.

Escludendo la colonna relativa alla data (non utilizzabile direttamente come variabile numerica continua all'interno dei modelli spaziali), il dataset originale può essere scomposto in una matrice di *features* $\mathbf{X}$ in cui ogni colonna rappresenta il rendimento di un indice specifico. Gli attributi a disposizione per l'analisi sono i seguenti:

Tabella 1: Descrizione degli attributi finanziari presenti nel dataset.

Sigla	Indice	Descrizione della Variabile
ISE	Istanbul Stock Exchange	Rendimento borsa di Istanbul (Target)
SP	S&P 500	Indice azionario statunitense
DAX	DAX	Indice azionario tedesco
FTSE	FTSE 100	Indice azionario del Regno Unito
NIKKEI	NIKKEI 225	Indice azionario giapponese
BOVESPA	BOVESPA	Indice azionario brasiliano
EU	MSCI Europe	Indice di riferimento europeo
EM	MSCI EM	Indice dei mercati emergenti

L'obiettivo principale dell'analisi è addestrare diversi modelli di Machine Learning per risolvere un problema di classificazione resa binaria: prevedere se l'indice della borsa di Istanbul (ISE) registrerà un rendimento positivo o negativo in base all'andamento degli altri mercati internazionali.

Essendo i dati originali di natura continua (rendimenti percentuali), si è reso necessario trasformare la variabile di output in una variabile categorica. Al fine di formulare un problema di classificazione, i dati sono stati discretizzati e raggruppati in due classi per creare la variabile *Target* y :

Definizione del Target Binarizzato

Per trasformare il problema di regressione dei rendimenti in una classificazione binaria, abbiamo definito la variabile Target y secondo la regola:

$$y = \begin{cases} 1 & \text{se ISE} > 0 \quad (\text{Rialzo}) \\ 0 & \text{se ISE} \leq 0 \quad (\text{Ribasso}) \end{cases} \quad (1)$$

1.2 Analisi della Correlazione

I mercati finanziari globali costituiscono sistemi complessi e intrinsecamente interconnessi. Prima di procedere con l'applicazione di algoritmi vari, è necessario investigare la struttura delle relazioni lineari esistenti tra le variabili predittive (gli indici azionari mondiali) per individuare ed eliminare eventuali informazioni poco rilevanti.

A tal fine, si introduce il coefficiente di correlazione lineare di Pearson. Date due generiche variabili aleatorie continue X_j e X_k , associate rispettivamente alle caratteristiche j -esima e k -esima del dataset, il coefficiente di correlazione di Pearson $\rho_{jk} \in [-1, 1]$ è definito formalmente come il rapporto tra la loro covarianza e il prodotto delle rispettive deviazioni standard:

$$\rho_{jk} = \frac{\text{Cov}(X_j, X_k)}{\sigma_j \sigma_k} = \frac{\mathbb{E}[(X_j - \mu_j)(X_k - \mu_k)]}{\sqrt{\mathbb{E}[(X_j - \mu_j)^2] \mathbb{E}[(X_k - \mu_k)^2]}} \quad (2)$$

Empiricamente, considerando un campione di n osservazioni, il coefficiente campionario r_{jk} si calcola come:

$$r_{jk} = \frac{\sum_{i=1}^n (x_{ij} - \hat{\mu}_j)(x_{ik} - \hat{\mu}_k)}{\sqrt{\sum_{i=1}^n (x_{ij} - \hat{\mu}_j)^2 \sum_{i=1}^n (x_{ik} - \hat{\mu}_k)^2}} \quad (3)$$

dove $\hat{\mu}_j$ e $\hat{\mu}_k$ rappresentano le medie campionarie delle due features.

Dal punto di vista algebrico, si dimostra che la matrice di correlazione di Pearson equivale in modo esatto alla matrice di covarianza calcolata sui dati precedentemente standardizzati.

Siano infatti $Z_j = \frac{X_j - \mu_j}{\sigma_j}$ e $Z_k = \frac{X_k - \mu_k}{\sigma_k}$ le variabili standardizzate associate, aventi per costruzione media nulla ($\mathbb{E}[Z_j] = 0$) e varianza unitaria ($\text{Var}(Z_j) = 1$). Sviluppando il calcolo della covarianza tra le variabili standardizzate si ottiene:

$$\text{Cov}(Z_j, Z_k) = \mathbb{E}[Z_j Z_k] = \frac{\mathbb{E}[(X_j - \mu_j)(X_k - \mu_k)]}{\sigma_j \sigma_k} = \frac{\text{Cov}(X_j, X_k)}{\sigma_j \sigma_k} \equiv \rho_{jk} \quad (4)$$

La matrice di covarianza della matrice dei dati standardizzati $\mathbf{Z}$ corrisponde dunque alla matrice di correlazione campionaria dei dati originali $\mathbf{X}$.

La Figura 1 mostra la heatmap della matrice di correlazione calcolata sul nostro dataset. Dall'analisi visiva emergono evidenze macroeconomiche di forte collinearità:

- Gli indici del blocco europeo (DAX, FTSE, EU) presentano correlazioni lineari estremamente elevate, con valori compresi tra **0.87** e **0.95**. Questa stretta sincronizzazione indica una profonda integrazione finanziaria, rendendo tali attributi parzialmente ridondanti per i modelli predittivi.
- Al contrario, l'indice giapponese NIKKEI mostra coefficienti significativamente inferiori rispetto a tutti gli altri mercati occidentali, con valori che oscillano tra **0.13** e **0.28**. Questa debole dipendenza è da attribuire probabilmente a fusi orari delle azioni delle borse asiatiche rispetto a quelle europee e americane.

La presenza di collinearità così marcata rappresenta una severa criticità per la stabilità numerica di molti algoritmi, incrementando il rumore e il rischio di overfitting. Questa evidenza statistica giustifica teoricamente l'adozione della PCA come tecnica non supervisionata volta a mappare i dati in uno spazio ortogonale eliminando la ridondanza informativa. (Figura 1).




Figura 1: Matrice di correlazione tra gli indici azionari mondiali.

Dunque, dall'analisi esplorativa della mappa gli indici del blocco europeo rappresentano una ridondanza informativa significativa che non solo introduce variabili quasi identiche nel modello, ma aumenta il rischio di instabilità algoritmica e complicazione computazionale.

1.3 Split dei dati e Scaling

Prima di procedere a qualsiasi trasformazione matematica, i dati sono stati partizionati in due sottoinsiemi: un *Training Set* contenente il 70% delle osservazioni, utilizzato per l'addestramento e la ricerca degli iperparametri, e un *Test Set* contenente il restante 30%, preservato unicamente per valutare le performance finali dei modelli su dati non visti. La validazione interna dei modelli è stata gestita tramite una 5-fold Cross-Validation operata esclusivamente sulla porzione di addestramento.

Effettuare il partizionamento originario (70/30) prima della fase di scalatura è fondamentale nell'apprendimento automatico per prevenire il fenomeno del **Data Leakage**. Se l'intero dataset fosse stato modificato in modo globale, le metriche del Test Set avrebbero condizionato indirettamente i parametri del Training Set, producendo stime di accuratezza eccessivamente ottimistiche ma fallaci.

Algoritmi geometrici basano i propri calcoli sulla minimizzazione e massimizzazione delle distanze nello spazio delle features, risultando altamente sensibili all'ampiezza delle variabili. Per evitare pesature artificiali, si è applicato uno *Standard Scaler*.

Questa operazione ha convertito ogni feature x in una variabile standardizzata z , imponendo media nulla e varianza unitaria:

$$z = \frac{x - \mu}{\sigma} \quad (5)$$

dove μ e σ sono rispettivamente la media e la deviazione standard calcolate *esclusivamente* sui dati del Training Set. Questi medesimi parametri di centratura e scalatura sono stati successivamente applicati per trasformare il Test Set, garantendo la totale indipendenza statistica delle due partizioni.

2 Riduzione della Dimensionalità

Le gravi criticità statistiche, dovute all'elevato numero di attributi ridondanti o non correlati, sono legate alla cosiddetta **Curse of Dimensionality** (Maledizione della Dimensionalità). Come formulato originariamente da R. Bellman nel 1957, all'aumentare delle dimensioni dello spazio delle caratteristiche, il volume dello spazio geometrico cresce esponenzialmente, rendendo i dati presenti estremamente sparsi. In uno spazio ad alta dimensionalità, tutti i punti campionari tendono a essere isolati e concentrati lungo i bordi esterni del dominio. La distanza euclidea tra i vettori si uniforma, portando al collasso di algoritmi basati sulla distanza locale come il k -Nearest Neighbors (k -NN). Nei modelli di classificazione supervisionata, questo fenomeno si manifesta attraverso il **Fenomeno di Hughes**: le prestazioni del classificatore degradano all'aumentare delle dimensioni a causa dell'overfitting sui dettagli del rumore di fondo del set di addestramento.

Per mitigare questi problemi, sono possibili ben due approcci algebrici distinti per la proiezione dei dati in spazi latenti a bassa dimensionalità: la **Principal Component Analysis (PCA)**, un metodo non supervisionato orientato alla conservazione della varianza dei dati, e la **Fisher Discriminant Analysis (FDA)**, un metodo supervisionato orientato alla massimizzazione della separabilità delle classi.

2.1 Principal Component Analysis (PCA)

L'Analisi delle Componenti Principali (PCA) è una tecnica di proiezione lineare non supervisionata che si propone di mappare un insieme di dati d -dimensionali in un nuovo sistema di coordinate ortogonali di dimensione $k < d$. La trasformazione è definita in modo tale che la prima coordinata (denominata prima componente principale, PC1) catturi la massima varianza possibile dei dati; ogni componente successiva deve risultare ortogonale alle precedenti e massimizzare la varianza residua dello spazio ortogonale complementare.

2.1.1 Formulazione Matematica del Problema di Ottimizzazione

Sia dato un set di dati $\mathcal{D} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\} \subset \mathbb{R}^d$ composto da n vettori colonna. Il primo passaggio algebrico prevede la rimozione dell'influenza della posizione dell'origine spaziale tramite il centramento dei dati rispetto alla media campionaria:

$$\hat{\boldsymbol{\mu}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \quad (6)$$

I vettori centrati si definiscono come:

$$\mathbf{z}_i = \mathbf{x}_i - \hat{\boldsymbol{\mu}}, \quad \forall i = 1, \dots, n \quad (7)$$

Definiamo la **Scatter Matrix** (matrice di dispersione) $\mathbf{S} \in \mathbb{R}^{d \times d}$ del dataset centrato come:

$$\mathbf{S} = \sum_{i=1}^n \mathbf{z}_i \mathbf{z}_i^T \quad (8)$$

Si osservi che la Scatter Matrix $\mathbf{S}$ è strettamente legata alla matrice di covarianza empirica $\hat{\boldsymbol{\Sigma}}$ tramite il fattore di scala $\mathbf{S} = (n-1)\hat{\boldsymbol{\Sigma}}$. Essa risulta simmetrica e semidefinita positiva per costruzione, garantendo l'esistenza di autovalori reali e non negativi.

Si consideri la proiezione dei punti centrati su un sottospazio lineare W di dimensione $k < d$, caratterizzato da una base ortonormale di vettori direzione $\{\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k\} \subset \mathbb{R}^d$. La rappresentazione del generico punto proiettato è data da:

$$\tilde{\mathbf{z}}_j = \sum_{i=1}^k \alpha_{ji} \mathbf{e}_i \quad (9)$$

Vogliamo trovare la base ortonormale $\{\mathbf{e}_i\}_{i=1}^k$ e i relativi coefficienti α_{ji} che minimizzino l'errore quadratico medio di ricostruzione J rispetto alle osservazioni originali centrati:

$$J = \sum_{j=1}^n \left\| \mathbf{z}_j - \sum_{i=1}^k \alpha_{ji} \mathbf{e}_i \right\|^2 \quad (10)$$

Per minimizzare J rispetto ai coefficienti di proiezione α_{ml} , imponiamo che la derivata parziale rispetto a ciascun coefficiente si annulli:

$$\frac{\partial J}{\partial \alpha_{ml}} = \frac{\partial}{\partial \alpha_{ml}} \sum_{j=1}^n \left(\mathbf{z}_j^T \mathbf{z}_j - 2 \sum_{i=1}^k \alpha_{ji} \mathbf{z}_j^T \mathbf{e}_i + \sum_{i=1}^k \alpha_{ji}^2 \right) = 0 \quad (11)$$

Risolviendo l'equazione lineare derivata, si ottiene che il coefficiente di ricostruzione ottimale corrisponde alla proiezione ortogonale del punto sulla direzione dell'autovettore della base:

$$-2\mathbf{z}_m^T \mathbf{e}_l + 2\alpha_{ml} = 0 \implies \alpha_{ml} = \mathbf{z}_m^T \mathbf{e}_l \quad (12)$$

Sostituendo la relazione ottimale $\alpha_{ji} = \mathbf{z}_j^T \mathbf{e}_i$ all'interno della funzione di costo J , e sfruttando le proprietà di ortonormalità della base proiettiva ($\mathbf{e}_i^T \mathbf{e}_l = \delta_{il}$), possiamo riscrivere l'errore totale come:

$$J = \sum_{j=1}^n \left(\mathbf{z}_j^T \mathbf{z}_j - \sum_{i=1}^k (\mathbf{z}_j^T \mathbf{e}_i)^2 \right) = \sum_{j=1}^n \|\mathbf{z}_j\|^2 - \sum_{i=1}^k \mathbf{e}_i^T \left(\sum_{j=1}^n \mathbf{z}_j \mathbf{z}_j^T \right) \mathbf{e}_i \quad (13)$$

Sostituendo la definizione della Scatter Matrix $\mathbf{S}$, otteniamo l'espressione finale per l'errore di ricostruzione:

$$J = \sum_{j=1}^n \|\mathbf{z}_j\|^2 - \sum_{i=1}^k \mathbf{e}_i^T \mathbf{S} \mathbf{e}_i \quad (14)$$

Poiché il termine $\sum_{j=1}^n \|\mathbf{z}_j\|^2$ rappresenta l'energia totale (o varianza totale) costante dei dati centrati originari, minimizzare l'errore quadratico di ricostruzione J equivale a massimizzare la somma della varianza proiettata lungo le direzioni dei vettori della base:

$$\max_{\{\mathbf{e}_1, \dots, \mathbf{e}_k\}} \sum_{i=1}^k \mathbf{e}_i^T \mathbf{S} \mathbf{e}_i \quad \text{s.t.} \quad \mathbf{e}_i^T \mathbf{e}_i = 1, \quad \forall i = 1, \dots, k \quad (15)$$

2.1.2 Risoluzione tramite Moltiplicatori di Lagrange

Per risolvere il problema di massimo vincolato per ciascuna direzione m -esima della base, definiamo la funzione Lagrangiana incorporando il vincolo di normalizzazione del vettore direzione mediante il moltiplicatore di Lagrange λ_m :

$$\mathcal{L}(\mathbf{e}_m, \lambda_m) = \mathbf{e}_m^T \mathbf{S} \mathbf{e}_m - \lambda_m (\mathbf{e}_m^T \mathbf{e}_m - 1) \quad (16)$$

Calcoliamo il gradiente rispetto al vettore colonna $\mathbf{e}_m$ e lo poniamo pari al vettore nullo:

$$\nabla_{\mathbf{e}_m} \mathcal{L} = 2\mathbf{S}\mathbf{e}_m - 2\lambda_m \mathbf{e}_m = \mathbf{0} \quad (17)$$

L'annullamento del gradiente conduce direttamente all'equazione caratteristica agli autovalori della Scatter Matrix:

$$\mathbf{S}\mathbf{e}_m = \lambda_m \mathbf{e}_m \quad (18)$$

Moltiplicando a sinistra entrambi i membri per $\mathbf{e}_m^T$ e sfruttando nuovamente il vincolo di normalizzazione $\mathbf{e}_m^T \mathbf{e}_m = 1$, si dimostra che il valore massimo della varianza spiegata lungo la direzione $\mathbf{e}_m$ coincide esattamente con l'autovalore λ_m ad essa associato:

$$\mathbf{e}_m^T \mathbf{S}\mathbf{e}_m = \mathbf{e}_m^T (\lambda_m \mathbf{e}_m) = \lambda_m (\mathbf{e}_m^T \mathbf{e}_m) = \lambda_m \quad (19)$$

Per minimizzare l'errore totale J , dobbiamo massimizzare la quantità proiettata selezionando i k autovettori di $\mathbf{S}$ associati ai k autovalori maggiori, ordinati in senso decrescente ($\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k \geq 0$). Definita la matrice di proiezione $\mathbf{E}_k = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_k] \in \mathbb{R}^{d \times k}$, il vettore a dimensionalità ridotta $\mathbf{y}_j \in \mathbb{R}^k$ associato al campione originale standardizzato si ricava come:

$$\mathbf{y}_j = \mathbf{E}_k^T \mathbf{z}_j \quad (20)$$

2.1.3 Connessione con la Decomposizione ai Valori Singolari (SVD)

Sotto il profilo del calcolo numerico, la determinazione delle componenti principali mediante la diagonalizzazione esplicita della Scatter Matrix $\mathbf{S}$ (o della matrice di covarianza $\hat{\Sigma}$) può indurre instabilità e arrotondamenti numerici deleteri, specialmente in presenza di forte multicollinearità. Il metodo più robusto ed efficiente dal punto di vista computazionale prevede l'applicazione della Decomposizione ai Valori Singolari (SVD) direttamente sulla matrice centrata dei dati $\mathbf{Z} \in \mathbb{R}^{n \times d}$, le cui righe contengono i vettori riga centrati $\mathbf{z}_i^T$.

La scomposizione SVD della matrice $\mathbf{Z}$ è definita come:

$$\mathbf{Z} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (21)$$

dove $\mathbf{U} \in \mathbb{R}^{n \times n}$ e $\mathbf{V} \in \mathbb{R}^{d \times d}$ sono matrici ortonormali che contengono rispettivamente i vettori singolari sinistri e destri di $\mathbf{Z}$, mentre $\mathbf{\Sigma} \in \mathbb{R}^{n \times d}$ è una matrice rettangolare diagonale contenente sulla diagonale principale i valori singolari non negativi $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_d \geq 0$.

Calcoliamo ora esplicitamente il prodotto $\mathbf{Z}^T \mathbf{Z}$, che rappresenta la definizione algebrica della Scatter Matrix $\mathbf{S}$:

$$\mathbf{S} = \mathbf{Z}^T \mathbf{Z} = (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T)^T (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T) = \mathbf{V}\mathbf{\Sigma}^T \mathbf{U}^T \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \quad (22)$$

Sfruttando l'ortonormalità della matrice $\mathbf{U}$ (che implica $\mathbf{U}^T \mathbf{U} = \mathbf{I}$), l'espressione si semplifica in:

$$\mathbf{S} = \mathbf{V}(\mathbf{\Sigma}^T \mathbf{\Sigma})\mathbf{V}^T = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T \quad (23)$$

dove $\mathbf{\Lambda} = \mathbf{\Sigma}^T \mathbf{\Sigma} \in \mathbb{R}^{d \times d}$ è una matrice diagonale contenente gli autovalori $\lambda_i = \sigma_i^2$. Questo passaggio dimostra in modo formale che:

1. I vettori singolari destri della matrice dei dati centrati (le colonne di $\mathbf{V}$) coincidono in modo esatto con gli autovettori della Scatter Matrix $\mathbf{S}$ (le componenti principali ricercate).
2. Gli autovalori della matrice di dispersione coincidono con il quadrato dei valori singolari della matrice dei dati centrati ($\lambda_i = \sigma_i^2$).

L'applicazione diretta di algoritmi di calcolo della SVD a bassi costi computazionali permette dunque di evitare l'elevamento al quadrato delle relazioni di dispersione, minimizzando gli errori di precisione di macchina ed escludendo le componenti associate a valori singolari trascurabili.

2.1.4 Analisi Empirica dei Risultati della PCA sul Dataset Finanziario

Nel presente studio sul dataset `data_akbilgic.xlsx`, la matrice delle features $\mathbf{X}$ raccoglie le fluttuazioni giornaliere dei rendimenti di sette indici di borsa mondiali: SP (Stati Uniti), DAX (Germania), FTSE (Regno Unito), NIKKEI (Giappone), BOVESPA (Brasile), EU (Unione Europea) ed EM (Mercati Emergenti). Prima di calcolare le componenti, è stato applicato uno `StandardScaler` per imporre media nulla e varianza unitaria a ciascun indice, impedendo che gli indici caratterizzati da una volatilità elevata dominassero la scomposizione geometrica, alterando la struttura di covarianza del mercato globale.




Figura 2: Andamento della frazione di varianza spiegata cumulativa in funzione del numero di Componenti Principali.

L'analisi della frazione di varianza spiegata cumulativa (EVR), illustrata in Figura 2, evidenzia la forte interconnessione macroeconomica che governa i mercati finanziari internazionali:

- La prima singola Componente Principale (PC1) cattura da sola ben il **65.8%** della varianza totale del sistema. Sotto il profilo dell'analisi economica, questo risultato empirico è di estremo interesse: la concentrazione di quasi due terzi della dispersione complessiva su un unico asse latente riflette l'esistenza di un "trend sistemico globale" o "fattore di mercato globale". Questo fattore dominante guida i movimenti coordinati di tutti gli indici indipendentemente dall'area geografica, testimoniando gli effetti profondi della globalizzazione finanziaria.
- La seconda Componente Principale (PC2) cattura il **14.9%** della varianza residua. La combinazione delle prime due componenti (PC1 e PC2) consente di preservare oltre l' **80.7%** dell'informazione originale.
- Applicando una quota di varianza cumulativa pari ad almeno il **95%** (o l'85% in contesti più tolleranti), il numero ottimale di dimensioni latenti da preservare risulta essere $k = 4$, in grado di spiegare il **95.4%** della varianza campionaria complessiva. Questo permette di comprimere lo spazio originario del dataset da 7 variabili a sole 4 dimensioni latenti ortonormali, rimuovendo il rumore giornaliero ma conservando il potere predittivo per i classificatori.

Proiezione 3D del Dataset tramite PCA




Figura 3: Visualizzazione tridimensionale dei campioni sulle prime tre Componenti Principali.

La seguente Figura mostra la proiezione spaziale 3D dei campioni giornalieri sulle prime tre componenti principali (PC1, PC2, PC3), con i punti colorati in base al target binarizzato dell'indice ISE (Istanbul Stock Exchange): in blu le giornate di rialzo (Classe 1, $ISE > 0$) e in rosso le giornate di ribasso (Classe 0, $ISE \leq 0$). L'analisi visiva della nuvola tridimensionale rivela informazioni cruciali sulla separabilità del dataset:

- Nella regione centrale ad alta densità dello spazio latente, le due classi mostrano una forte e intrinseca sovrapposizione. Questa forte compenetrazione dei punti riflette la natura "rumorosa" delle giornate operative ordinarie, in cui i rendimenti fluttuano attorno allo zero con dinamiche casuali non linearmente separabili.
- Nelle zone esterne della nuvola spaziale (le code della distribuzione lungo gli assi PC1 e PC2), si osserva invece un inizio di segregazione geometrica delle classi. Le giornate caratterizzate da forti shock di mercato globali (grandi movimenti di rialzo o ribasso sistemico) si polarizzano in modo più netto lungo i bordi esterni dello spazio.

Questa specifica conformazione geometrica evidenzia i limiti insiti nei classificatori lineari classici (come l'LDA o le SVM a iperpiano lineare semplice) e giustifica pienamente la necessità di ricorrere a confini di decisione non lineari molto flessibili. L'uso di tecniche avanzate come le SVM con kernel Gaussiano (RBF) o le reti neurali artificiali Multi-Layer Perceptron (MLP) si rivela dunque la scelta ideale per mappare accuratamente le complesse superfici di separazione non lineari necessarie a risolvere il problema con alta precisione.

3 Modelli di Classificazione Supervisionata

In questo capitolo viene esaminato il cuore sperimentale e teorico del progetto. L'obiettivo è addestrare e valutare diversi algoritmi di apprendimento supervisionato per risolvere il problema di classificazione binaria associato alla previsione dell'indice finanziario della borsa di Istanbul (ISE). Al fine di comprendere l'impatto delle tecniche di riduzione della dimensionalità sulle performance predittive, ciascun classificatore viene analizzato in tre differenti configurazioni spaziali:

1. **Spazio Originale (7D):** Utilizzando l'insieme completo delle 7 features originali standardizzate.
2. **Spazio PCA (4D):** Utilizzando la proiezione sulle prime 4 componenti principali che spiegano il 95.4% della varianza cumulativa totale.
3. **Spazio FDA (1D):** Utilizzando la retta discriminante ottimale calcolata supervisionando le classi.

3.1 Metodologia di Valutazione e Metriche d'Errore

Trattandosi di un problema di classificazione in cui l'accuratezza globale può risultare una metrica fuorviante (specialmente in presenza di distribuzioni di classi non perfettamente bilanciate o di asimmetrie nel costo degli errori), si rende necessario definire un insieme completo di metriche statistiche basate sul conteggio degli errori di classificazione. Consideriamo una classificazione binaria in cui la Classe 1 rappresenta la classe positiva (giornata di rialzo dell'indice, $ISE > 0$) e la Classe 0 la classe negativa (giornata di ribasso, $ISE \leq 0$). Definiamo i seguenti quattro scenari elementari sul Test Set $\mathcal{P}$:

- **True Positive (TP):** Numero di campioni appartenenti alla Classe 1 correttamente classificati come Classe 1.
- **True Negative (TN):** Numero di campioni appartenenti alla Classe 0 correttamente classificati come Classe 0.
- **False Positive (FP):** Numero di campioni appartenenti alla Classe 0 erroneamente classificati come Classe 1 (errore di tipo I).
- **False Negative (FN):** Numero di campioni appartenenti alla Classe 1 erroneamente classificati come Classe 0 (errore di tipo II).

A partire da tali conteggi, definiamo l'**Accuratezza (Accuracy)** come la frazione di predizioni corrette sull'intero dataset:

$$\text{acc}(\mathcal{P}) = \frac{TP + TN}{TP + TN + FP + FN} \quad (24)$$

Metriche Fondamentali per la Valutazione

Dai conteggi della matrice di confusione, definiamo le metriche di accuratezza locale e bilanciamento:

$$\text{Precision}(C_i) = \frac{TP}{TP + FP} \quad (25)$$

$$\text{Recall}(C_i) = \frac{TP}{TP + FN} \quad (26)$$

$$F_1\text{-score}(C_i) = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (27)$$

L'analisi visiva di tali metriche è facilitata dalla costruzione della **Matrice di Confusione** $\mathbf{A} \in \mathbb{R}^{2 \times 2}$, definita in modo tale che l'elemento a_{ij} rappresenti il numero di campioni appartenenti alla classe reale i che sono stati predetti come appartenenti alla classe j :

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} = \begin{bmatrix} TP & FN \\ FP & TN \end{bmatrix} \quad (28)$$

Si osserva che la traccia della matrice $\text{tr}(\mathbf{A}) = TP + TN$ rappresenta la somma delle predizioni corrette, mentre gli elementi fuori dalla diagonale principale rappresentano gli errori commessi dal modello.

3.2 k-Nearest Neighbors (k-NN)

Il classificatore k -Nearest Neighbors (k -NN) è un algoritmo di apprendimento non parametrico e *instance-based*. A differenza di altri modelli, non richiede una fase di addestramento esplicita per stimare parametri globali, ma memorizza i vettori del Training Set per effettuare predizioni basandosi su criteri di similarità geometrica locale.

3.2.1 Formulazione Matematica della Regola di Decisione

Sia $\mathbf{x} \in \mathbb{R}^d$ un generico vettore di test da classificare. L'algoritmo calcola la distanza euclidea tra $\mathbf{x}$ e tutti i vettori $\mathbf{x}_i$ appartenenti al Training Set T :

$$d(\mathbf{x}, \mathbf{x}_i) = \|\mathbf{x} - \mathbf{x}_i\|_2 = \sqrt{\sum_{j=1}^d (x_j - x_{ij})^2} \quad (29)$$

Identificato l'insieme $N_k(\mathbf{x}) \subset T$ contenente i k campioni a distanza minima da $\mathbf{x}$, l'assegnazione della classe può avvenire secondo due schemi di voto principali:

1. **Pesi Uniformi (Majority Vote):** Ciascun vicino esprime un voto identico. La classe predetta $\hat{y}$ corrisponde alla moda delle etichette dei vicini:

$$\hat{y} = \arg \max_{c \in \{0,1\}} \sum_{\mathbf{x}_i \in N_k(\mathbf{x})} \mathbb{I}(y_i = c) \quad (30)$$

dove $\mathbb{I}(\cdot)$ è la funzione indicatrice. In presenza di classificazione multi-classe, questo metodo può presentare situazioni di pareggio indeterminato.

2. **Pesi Inversamente Proporzionali alla Distanza:** Per ovviare all'influenza di vicini geometricamente distanti che potrebbero alterare i confini decisionali locali (soprattutto in aree ad alta densità in cui le classi sono compenstrate), il voto di ciascun vicino viene pesato in base all'inverso della sua distanza:

$$w_i = \frac{1}{d(\mathbf{x}, \mathbf{x}_i) + \epsilon} \quad (31)$$

dove $\epsilon > 0$ è un termine infinitesimo per prevenire la divisione per zero nel caso in cui il punto di test coincida esattamente con un punto di addestramento. La regola di decisione pesata diventa:

$$\hat{y} = \arg \max_{c \in \{0,1\}} \sum_{\mathbf{x}_i \in N_k(\mathbf{x})} w_i \mathbb{I}(y_i = c) \quad (32)$$

L'iperparametro k controlla il trade-off complessità-approssimazione del modello. Valori estremamente bassi (es. $k = 1$) portano a superfici decisionali molto complesse e frammentate, con accuratezza sul Training Set pari al 100% ma elevata varianza sul Test Set (overfitting). Al contrario, valori di k troppo elevati tendono ad appiattire la struttura dei dati, allineando la classificazione con la classe maggioritaria del dataset (underfitting).

3.2.2 Risultati Sperimentali e Analisi Comparativa degli Spazi

Nel nostro studio, l'algoritmo k -NN è stato impostato manualmente al valore $k = 5$. I risultati evidenziano dinamiche spaziali differenti:

- **Spazio Originale (7D):** L'accuratezza ottimale sul Test Set, si attesta al **73.91%** con $k = 5$ e pesi uniformi. L'applicazione dei pesi con inverso della distanza mostra stabilità ma non incrementa le prestazioni globali a causa della dimensionalità che distribuisce i punti uniformemente.
- **Spazio PCA (4D):** La proiezione sullo spazio latente ortogonale della PCA porta l'accuratezza al **72.67%**. Sebbene vi sia una leggera flessione dovuta alla perdita del 4.6% di varianza originale, lo spazio ridotto garantisce una stabilità computazionale superiore e confini più regolari, riducendo la sensibilità al rumore finanziario locale.

- **Spazio FDA (1D):** Nello spazio monodimensionale calcolato tramite FDA, il k -NN sperimenta un netto degrado delle prestazioni, crollando al **69.57%** di accuratezza. Questo comportamento è una diretta conseguenza della *Curse of Dimensionality* operata all'inverso: comprimere le features in una singola dimensione proiettiva schiaccia i vicini l'uno sull'altro, mescolando i punti delle due classi lungo l'unica retta e distruggendo la località geometrica dell'informazione su cui si fonda l'algoritmo.

3.3 Linear Discriminant Analysis (LDA)

La Linear Discriminant Analysis (LDA) rappresenta un approccio classico e probabilistico alla classificazione. A differenza del k -NN, l'LDA è un modello generativo che tenta di modellare esplicitamente la distribuzione di probabilità congiunta delle caratteristiche per ciascuna classe per poi applicare il Teorema di Bayes.

3.3.1 Formulazione Bayesiana sotto Omoschedasticità

Dato un vettore di caratteristiche $\mathbf{x} \in \mathbb{R}^d$, si vuole calcolare la probabilità a posteriori che esso appartenga alla classe $k \in \{0, 1\}$:

$$P(Y = k | X = \mathbf{x}) = \frac{P(X = \mathbf{x} | Y = k)P(Y = k)}{P(X = \mathbf{x})} = \frac{f_k(\mathbf{x})\pi_k}{\sum_{l=0}^1 f_l(\mathbf{x})\pi_l} \quad (33)$$

dove $\pi_k \in (0, 1)$ rappresenta la probabilità a priori della classe k , stimata empiricamente come la frequenza relativa dei campioni nel Training Set $\hat{\pi}_k = n_k/n$. L'ipotesi teorica fondamentale dell'LDA prevede che le densità di probabilità condizionate delle classi $f_k(\mathbf{x})$ seguano una distribuzione Gaussiana multivariata:

$$f_k(\mathbf{x}) = \frac{1}{(2\pi)^{d/2} |\Sigma_k|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right) \quad (34)$$

Inoltre, l'LDA assume l'ipotesi di **Omoschedasticità**, per cui tutte le classi condividono la medesima matrice di covarianza $\Sigma_1 = \Sigma_0 = \Sigma$. Per classificare il punto, cerchiamo la classe che massimizza la probabilità a posteriori. Escludendo i termini comuni a denominatore e applicando il logaritmo naturale (funzione strettamente monotona crescente), definiamo la funzione discriminante lineare $\delta_k(\mathbf{x})$:

$$\delta_k(\mathbf{x}) = \ln(f_k(\mathbf{x})\pi_k) = \ln \pi_k - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln |\Sigma| - \frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \quad (35)$$

Sviluppando il prodotto quadratico ed eliminando il termine costante $\frac{1}{2} \mathbf{x}^T \Sigma^{-1} \mathbf{x}$ (che non dipende dall'indice di classe k), la funzione si riduce a una combinazione lineare rispetto alle coordinate del punto:

$$\delta_k(\mathbf{x}) = \mathbf{x}^T \Sigma^{-1} \boldsymbol{\mu}_k - \frac{1}{2} \boldsymbol{\mu}_k^T \Sigma^{-1} \boldsymbol{\mu}_k + \ln \pi_k \quad (36)$$

La superficie di separazione tra le due classi è identificata dal luogo dei punti in cui le due funzioni discriminanti assumono valore identico, ovvero $\delta_1(\mathbf{x}) = \delta_0(\mathbf{x})$. Sviluppando l'uguaglianza si ricava l'equazione di un iperpiano lineare in $\mathbb{R}^d$:

$$\mathbf{x}^T \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) - \frac{1}{2} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_0)^T \Sigma^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_0) + \ln \left(\frac{\pi_1}{\pi_0} \right) = 0 \quad (37)$$

3.3.2 Analisi Empirica dei Risultati dell'LDA

I risultati sperimentali mostrano che l'LDA beneficia in modo marcato delle tecniche di riduzione non supervisionata:

- **Spazio Originale (7D):** L'LDA ottiene un'accuratezza sul Test Set pari al **72.05%**. Questo risultato, pur discreto, risente della forte collinearità lineare presente tra le features (in particolare tra gli indici europei DAX, FTSE ed EU, che superano correlazioni di 0.90). La presenza di variabili fortemente correlate rende la matrice di covarianza campionaria $\hat{\Sigma}$ quasi singolare (mal condizionata), introducendo instabilità nel calcolo della sua inversa $\hat{\Sigma}^{-1}$ e riducendo l'efficacia dei confini decisionali lineari.

- **Spazio PCA (4D):** Proiettando i dati sulle prime 4 componenti della PCA, l'accuratezza sale al **75.16%**. Questo significativo incremento rappresenta una chiara conferma empirica della teoria: la PCA estrae caratteristiche latenti tra loro perfettamente ortogonali, eliminando completamente la multicollinearità delle features. La Scatter Matrix risultante nello spazio PCA è diagonale, garantendo un condizionamento numerico ottimale per l'inversione ed eliminando il rumore macroeconomico ad alta frequenza che ostacolava la generalizzazione dell'iperpiano.
- **Spazio FDA (1D):** Nello spazio supervisionato 1D, l'LDA mantiene un'accuratezza del **72.05%**. Si osserva che questo valore coincide esattamente con quello dello spazio originale. Questa equivalenza non è casuale: sotto l'ipotesi di omoschedasticità gaussiana, lo spazio proiettivo ottimo calcolato dalla FDA coincide (a meno di un fattore di scala costante) con la proiezione ortogonale effettuata dall'iperpiano di decisione dell'LDA, confermando l'equivalenza algebrica studiata a lezione.

3.4 SVM Non Lineari

Le Support Vector Machines (SVM) si configurano come una delle metodologie più solide e matematicamente fondate nel panorama dell'apprendimento supervisionato per la classificazione. Sviluppate originariamente da Vladimir Vapnik e dai suoi collaboratori, le SVM si basano sul principio di minimizzazione del rischio strutturale, che mira a massimizzare la capacità di generalizzazione del modello controllando contemporaneamente l'errore sul set di addestramento e la complessità geometrica della superficie decisionale.

3.4.1 Formulazione Primale a Soft Margin

Si consideri un dataset di addestramento composto da coppie di vettori e relative etichette binarie, dove le classi sono mappate nell'intervallo simmetrico $\{-1, +1\}$ per comodità di trattazione algebrica. Nel caso in cui i dati non siano perfettamente separabili linearmente a causa della presenza di rumore intrinseco o di sovrapposizioni strutturali (caratteristica tipica dei rendimenti giornalieri degli indici finanziari), l'imposizione di un vincolo di separazione rigido comporterebbe l'inesistenza di una soluzione ammissibile. Per superare tale limitazione, si introduce una formulazione a margine morbido (*Soft Margin*) che ammette la possibilità di violare i confini del margine ottimale o di commettere errori di classificazione sul Training Set. Questo rilassamento viene formalizzato attraverso l'introduzione delle variabili di tolleranza non negative, denominate **variabili di slack** $\xi_i \geq 0$, le quali misurano la distanza tra il campione generico e il rispettivo bordo del margine ottimale.

Formulazione Primale delle SVM a Margine Morbido

Il calcolo dell'iperpiano separatore ottimale in presenza di rumore si formula come un problema di programmazione quadratica:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^m \xi_i \quad (38)$$

soggetto ai vincoli di consistenza geometrica:

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i = 1, \dots, m \quad (39)$$

Il parametro reale positivo $C > 0$ agisce come costante di regolarizzazione ed esprime il trade-off tra due obiettivi contrastanti: la massimizzazione del margine geometrico (pari a $2/\|\mathbf{w}\|$, che equivale alla minimizzazione del termine di regolarizzazione quadratica $\frac{1}{2}\|\mathbf{w}\|^2$) e la penalizzazione degli errori di addestramento tramite la somma delle variabili di slack. All'aumentare di C , il modello penalizza severamente ogni singola violazione, tendendo verso un comportamento rigido (*Hard Margin*) ad alto rischio di overfitting; al diminuire di C , il margine diventa più tollerante e morbido, favorendo la capacità di generalizzazione su dati non visti a scapito di una minore accuratezza locale.

3.4.2 Derivazione del Problema Duale e Condizioni KKT

La risoluzione del problema primale vincolato viene condotta definendo la funzione Lagrangiana classica, la quale associa ai vincoli del problema i vettori dei moltiplicatori di Lagrange non negativi $\alpha =$

$[\alpha_1, \dots, \alpha_m]^T$ e $\beta = [\beta_1, \dots, \beta_m]^T$:

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \mathbf{w}^T \mathbf{w} + C \sum_{i=1}^m \xi_i - \sum_{i=1}^m \alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^m \beta_i \xi_i \quad (40)$$

Per il teorema di dualità forte, poiché la funzione obiettivo primale è convessa e i vincoli sono affini, la soluzione ottima coincide con il punto di sella della Lagrangiana. Imponendo la stazionarietà del gradiente di $\mathcal{L}$ rispetto alle variabili primali $(\mathbf{w}, b, \xi)$, si ricavano le seguenti equazioni di consistenza:

$$\nabla_{\mathbf{w}} \mathcal{L} = \mathbf{w} - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i = \mathbf{0} \implies \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \quad (41)$$

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^m \alpha_i y_i = 0 \implies \sum_{i=1}^m \alpha_i y_i = 0 \quad (42)$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C - \alpha_i - \beta_i = 0 \implies \alpha_i + \beta_i = C, \quad \forall i = 1, \dots, m \quad (43)$$

Poiché i moltiplicatori di Lagrange devono soddisfare i vincoli di non negatività ($\alpha_i \geq 0, \beta_i \geq 0$), l'ultima relazione impone che i coefficienti α_i siano superiormente limitati dalla costante di regolarizzazione, definendo il vincolo a scatola (*box constraint*):

$$0 \leq \alpha_i \leq C, \quad \forall i = 1, \dots, m \quad (44)$$

Sostituendo queste relazioni all'interno della Lagrangiana, si elimina la dipendenza dalle variabili primali e si ottiene la formulazione del **Problema Duale di Ottimizzazione**:

$$\max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j \quad (45)$$

soggetto ai vincoli di uguaglianza e di frontiera:

$$\sum_{i=1}^m \alpha_i y_i = 0 \quad \text{e} \quad 0 \leq \alpha_i \leq C, \quad \forall i = 1, \dots, m \quad (46)$$

Il punto ottimo deve soddisfare le condizioni di complementarità di Karush-Kuhn-Tucker (KKT), che legano le variabili primali e duali:

$$\alpha_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1 + \xi_i] = 0, \quad \forall i = 1, \dots, m \quad (47)$$

$$\beta_i \xi_i = (C - \alpha_i) \xi_i = 0, \quad \forall i = 1, \dots, m \quad (48)$$

L'analisi di queste condizioni permette di classificare geometricamente i campioni del dataset in base al valore ottimale del moltiplicatore α_i^* :

- Se $\alpha_i^* = 0$, il campione $\mathbf{x}_i$ giace al di fuori del canale del margine, sul lato corretto della superficie decisionale. Esso non contribuisce in alcun modo alla definizione dell'iperpiano ottimo.
- Se $0 < \alpha_i^* < C$, la condizione di complementarità impone $\xi_i = 0$, implicando che il punto si trova esattamente sul bordo del margine ottimale ($y_i(\mathbf{w}^T \mathbf{x}_i + b) = 1$). Tali punti costituiscono i **Vettori di Supporto Rigidi** (*Margin Support Vectors*).
- Se $\alpha_i^* = C$, allora la variabile di slack può essere strettamente positiva ($\xi_i > 0$), indicando che il punto viola il margine. Tali campioni sono definiti **Vettori di Supporto Non Rigidi** (*Non-margin Support Vectors*) e si trovano all'interno del margine o sul lato errato del confine di decisione.

Il vettore dei pesi ottimo $\mathbf{w}^*$ è espresso unicamente come combinazione lineare dei soli Vettori di Supporto (l'insieme dei punti per cui $\alpha_i^* > 0$), dimostrando la sparsità intrinseca del modello:

$$\mathbf{w}^* = \sum_{i \in I_{sv}} \alpha_i^* y_i \mathbf{x}_i \quad (49)$$

3.4.3 Il "Kernel Trick" e gli Spazi di Hilbert a Nucleo Riproduttore (RKHS)

Qualora la superficie di separazione tra le classi sia intrinsecamente non lineare, la ricerca di un iperpiano lineare nello spazio originale genera tassi d'errore elevati. La soluzione teorica consiste nel mappare i dati originari in uno spazio di feature a dimensionalità superiore (teoricamente infinita) $\mathcal{H}$ tramite una funzione di mappatura non lineare $\Phi : \mathbb{R}^d \rightarrow \mathcal{H}$, sperando che in tale spazio i dati diventino linearmente separabili, come schematizzato nella Figura 4.




Figura 4: Mappatura non lineare tramite funzione di feature Φ da uno spazio bidimensionale non separabile a uno tridimensionale linearmente separabile.

Tuttavia, calcolare esplicitamente le coordinate dei vettori trasformati $\Phi(\mathbf{x}_i)$ e i loro prodotti scalari in $\mathcal{H}$ risulterebbe computazionalmente proibitivo o matematicamente impossibile se la dimensione di $\mathcal{H}$ fosse infinita. Per ovviare a questo problema, si sfrutta il **Kernel Trick**: poiché sia il problema duale di ottimizzazione che la funzione decisionale dipendono esclusivamente dal prodotto scalare tra i vettori, è possibile sostituire tale operazione con una funzione nucleo o **Kernel** $K(\mathbf{x}_i, \mathbf{x}_j)$ che calcola direttamente il prodotto scalare nello spazio di arrivo rimanendo nello spazio originario:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \langle \Phi(\mathbf{x}_i), \Phi(\mathbf{x}_j) \rangle_{\mathcal{H}} \quad (50)$$

Affinché una funzione $K : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ sia un kernel valido (ovvero esista uno Spazio di Hilbert associato in cui essa rappresenti un prodotto scalare), essa deve soddisfare le condizioni del Teorema di Mercer, ovvero deve essere una funzione simmetrica e semidefinita positiva (**PDS - Positive Definite Symmetric**).

Nel presente lavoro, l'ottimizzazione si è focalizzata sull'impiego del kernel **Radial Basis Function (RBF)**, o gaussiano, definito come:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2) \quad (51)$$

dove l'iperparametro libero $\gamma > 0$ governa l'ampiezza della campana gaussiana e definisce il raggio di influenza locale dei singoli vettori di supporto. Valori di γ elevati comportano un'influenza molto localizzata dei punti di supporto, generando confini decisionali complessi e ad alta varianza; valori contenuti di γ tendono invece ad appiattire la superficie, estendendo l'influenza dei punti e producendo modelli più stabili e lisci. La funzione discriminante finale per la classificazione di un nuovo vettore $\mathbf{x}$ si esprime nella forma duale proiettata:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i \in I_{sv}} \alpha_i^* y_i K(\mathbf{x}_i, \mathbf{x}) + b^* \right) \quad (52)$$

3.4.4 Analisi dei Risultati Empirici sul Dataset Finanziario

L'addestramento del modello Kernel SVM sul dataset degli indici finanziari è stato ottimizzato integrando lo strumento **StandardScaler** e la classe **SVC** di Scikit-Learn all'interno di una pipeline di calcolo protetta contro il data leakage. La determinazione della miglior combinazione degli iperparametri è stata condotta tramite una ricerca a griglia (*Grid Search*) con 5-fold Cross-Validation stratificata, esplorando un intervallo logaritmico per C e per γ . La Figura 5 illustra il comportamento geometrico del confine decisionale

indotto dal kernel gaussiano proiettando il dataset bidimensionalmente e mostrando la corrispondente superficie di decisione tridimensionale calcolata per via numerica.




Figura 5: A sinistra: Confine decisionale non lineare nello spazio delle prime due componenti principali. A destra: Rappresentazione della superficie di decisione 3D generata dal kernel RBF.

L'analisi delle prestazioni del classificatore nello spazio latente ridotto della PCA a 4 componenti principali evidenzia il raggiungimento di un'accuratezza sul Test Set pari al **75.78%**, confermando l'ottima capacità predittiva del modello. Per comprendere a fondo la dinamica delle predizioni, si esamina la matrice di confusione sul Test Set riportata nella Figura 6.




Figura 6: Matrice di confusione sul Test Set per la Kernel SVM ottimizzata nello spazio PCA (4D).

La distribuzione degli errori evidenzia un forte comportamento asimmetrico:

- Sulla **Classe 1 (Mercato in Rialzo, $ISE > 0$)**, La SVM mostra un'elevata Recall sulla classe positiva registrando **82 Veri Positivi** e solo **17 Falsi Negativi**, corrispondenti a un valore di **Recall del 82.83%**.
- Sulla **Classe 0 (Mercato in Ribasso, $ISE \leq 0$)**, le performance risultano significativamente inferiori, con **40 Veri Negativi** individuati a fronte di ben **22 Falsi Positivi** (giornate di ribasso erroneamente classificate come rialzo), corrispondenti a una Recall del **64.52%**.

Sotto il profilo dell'interpretazione economico-finanziaria, questa marcata asimmetria riflette la natura asimmetrica delle relazioni che legano i mercati emergenti a quelli globali. Durante le fasi di espansione

globale, i mercati internazionali (S&P 500, DAX, indici europei) mostrano andamenti rialzisti fortemente sincronizzati che forniscono un segnale predittivo pulito e forte per anticipare la crescita dell'indice di Istanbul (ISE). Al contrario, le correzioni giornaliere e i ribassi minori dell'ISE sono spesso guidati da dinamiche politiche interne, instabilità locali o shock geopolitici idiosincratici della Turchia che non presentano alcuna correlazione lineare o dipendenza geometrica con i rendimenti delle borse estere occidentali. Questa carenza informativa di base nelle features giustifica matematicamente l'elevata quota di Falsi Positivi commessi dal modello.

3.5 Multi-Layer Perceptron (MLP)

I Multi-Layer Perceptrons (MLP) costituiscono l'architettura di riferimento nel campo delle reti neurali artificiali feed-forward. Essi estendono la capacità di modellazione dei classificatori lineari introducendo una struttura gerarchica multilivello basata sull'applicazione sequenziale di trasformazioni affini e funzioni di attivazione non lineari, per approssimare funzioni continue.

3.5.1 Architettura e Propagazione in Avanti (Feed-Forward)

La rete neurale progettata per la classificazione del dataset è strutturata in un livello di input contenente i nodi associati alle caratteristiche d'ingresso, una sequenza di livelli nascosti completamente connessi (*fully connected layers*) e un livello di output. Nel nostro scenario ottimale, l'architettura prevede 5 livelli nascosti composti da 200 neuroni ciascuno. Sia $\mathbf{h}^{(l)} \in \mathbb{R}^{n_l}$ il vettore dei segnali di attivazione emessi dal livello l -esimo (con $l = 1, \dots, H$, dove $H = 5$ è il numero di strati nascosti). La propagazione del segnale in avanti avviene calcolando, per ciascun livello, la combinazione affine delle uscite del livello precedente ed applicando ad essa la funzione di attivazione non lineare σ :

$$\mathbf{a}^{(l)} = \mathbf{W}^{(l)}\mathbf{h}^{(l-1)} + \mathbf{b}^{(l)} \quad (53)$$

$$\mathbf{h}^{(l)} = \sigma(\mathbf{a}^{(l)}) \quad (54)$$

dove $\mathbf{W}^{(l)} \in \mathbb{R}^{n_l \times n_{l-1}}$ rappresenta la matrice dei pesi sinaptici del livello l , $\mathbf{b}^{(l)} \in \mathbb{R}^{n_l}$ è il vettore dei bias di livello, e $\mathbf{a}^{(l)}$ indica il vettore dei pre-attivazione. Per il livello di input, si pone per convenzione $\mathbf{h}^{(0)} = \mathbf{x} \in \mathbb{R}^d$. Per i livelli nascosti della rete, si è utilizzata la funzione di attivazione **tangente iperbolica** ($\tanh$), che mappa l'intervallo reale nell'intervallo aperto $(-1, 1)$ garantendo la simmetria rispetto all'origine e la differenziabilità in ogni punto del dominio:

$$\sigma(a) = \tanh(a) = \frac{e^a - e^{-a}}{e^a + e^{-a}} \quad (55)$$

Per il livello di output, dovendo il modello restituire una stima della probabilità a posteriori di appartenenza alla classe positiva $P(Y = 1|X = \mathbf{x})$, viene impiegata la **funzione logistica sigmoidale**:

$$\hat{y} = \mathbf{h}^{(H+1)} = \text{sigm}(a^{(H+1)}) = \frac{1}{1 + e^{-a^{(H+1)}}} \quad (56)$$

Funzione di Costo: Binary Cross-Entropy Loss

L'addestramento della rete neurale avviene minimizzando la discrepanza tra le probabilità predette $\hat{y}_i$ e i target reali $y_i \in \{0, 1\}$:

$$\text{Loss}(\mathbf{W}, \mathbf{b}) = -\frac{1}{n} \sum_{i=1}^n [y_i \ln(\hat{y}_i) + (1 - y_i) \ln(1 - \hat{y}_i)] \quad (57)$$

3.5.2 Algoritmo di Back-Propagation e Ottimizzazione Adam

La minimizzazione della loss rispetto all'enorme spazio dei parametri della rete richiede il calcolo esplicito del gradiente. L'algoritmo di **Back-propagation (retropropagazione dell'errore)** risolve questo problema computazionale propagando all'indietro i segnali d'errore a partire dallo strato di output fino a quello di input, sfruttando la regola della catena per le derivate parziali.

Definito l'errore del livello di output L come la derivata della loss rispetto all'input pre-attivazione $\mathbf{a}^{(l)}$, per l'ultimo livello si ricava:

$$\delta^{(H+1)} = \frac{\partial \text{Loss}}{\partial \mathbf{a}^{(H+1)}} = \hat{\mathbf{y}} - \mathbf{y} \quad (58)$$

Per i livelli nascosti precedenti ($l = H, H-1, \dots, 1$), l'errore viene propagato all'indietro proiettando il vettore d'errore del livello successivo tramite la trasposta della matrice dei pesi e moltiplicando elemento per elemento per la derivata prima della funzione di attivazione locale valutata sul vettore di pre-attivazione:

$$\delta^{(l)} = \left((\mathbf{W}^{(l+1)})^T \delta^{(l+1)} \right) \odot \sigma'(\mathbf{a}^{(l)}) \quad (59)$$

dove, per la tangente iperbolica, la derivata prima assume la forma algebrica semplificata $\tanh'(a) = 1 - \tanh^2(a)$. Una volta determinati i vettori d'errore $\delta^{(l)}$ per ciascun livello, le derivate parziali della funzione di costo rispetto alle singole matrici dei pesi e ai vettori dei bias si calcolano istantaneamente come:

$$\frac{\partial \text{Loss}}{\partial \mathbf{W}^{(l)}} = \delta^{(l)} (\mathbf{h}^{(l-1)})^T, \quad \frac{\partial \text{Loss}}{\partial \mathbf{b}^{(l)}} = \delta^{(l)} \quad (60)$$

Per l'aggiornamento dei pesi, si adotta l'ottimizzatore **Adam (Adaptive Moment Estimation)**, un algoritmo di discesa del gradiente stocastico del primo ordine estremamente efficiente. Adam combina i punti di forza dei metodi Momentum e AdaGrad calcolando tassi di apprendimento adattivi per ciascun parametro basandosi sulla stima della media mobile del gradiente (m_t) e della varianza mobile del gradiente (v_t):

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (61)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (62)$$

dove g_t rappresenta il gradiente al passo t , mentre $\beta_1, \beta_2 \in [0, 1)$ sono i coefficienti di decadimento esponenziale, tipicamente impostati di default a 0.9 e 0.999. I momenti stimati vengono corretti per compensare il bias iniziale dovuto all'inizializzazione a zero:

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (63)$$

La regola di aggiornamento finale dei pesi $\mathbf{W}$ assume la seguente forma stocastica stabile:

$$\mathbf{W}_{t+1} = \mathbf{W}_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (64)$$

dove η è il learning rate ed $\epsilon > 0$ è un termine infinitesimo per prevenire divisioni per zero.

3.5.3 Risultati Sperimentali e Analisi Comparativa

Le performance predittive dell'MLP addestrato sono state analizzate in funzione dello spazio di feature fornito in ingresso. I risultati d'accuratezza misurati sul Test Set per tutti i modelli sviluppati sono riportati graficamente nella Figura 7, che mette in evidenza l'effetto dei diversi spazi latenti.

L'analisi comparativa dei dati del grafico a barre rivela un'evidenza teorica di straordinario interesse:

- **Senza Riduzione (Spazio 7D):** L'MLP ottiene un'accuratezza modesta sul Test Set, pari al **67.70%**. Questo risultato deludente è dovuto alla forte presenza di collinearità tra i mercati azionari e al rumore di fondo che affligge le serie storiche finanziarie, portando la rete ad overfittare sui dettagli spuri del Training Set.
- **Spazio PCA (4D):** Introducendo la proiezione sulle prime 4 componenti della PCA, L'accuratezza dell'MLP sale al **77.64%**, registrando il valore più alto tra i modelli testati. Questo comportamento dimostra empiricamente la capacità della PCA di agire come un potente regolarizzatore geometrico: eliminando le ridondanze informative evidenziate nella heatmap di Pearson e scartando le ultime componenti associate al rumore macroeconomico ad alta frequenza, essa fornisce alla rete un segnale pulito e denso, favorendo la convergenza globale.
- **Spazio FDA (1D):** Comprimeo forzatamente le dimensioni a una sola coordinata proiettiva tramite FDA, le performance dell'MLP degradano scendendo al **72.67%**. Questa riduzione dimostra che una singola dimensione lineare non è sufficiente per preservare le relazioni complesse e non lineari necessarie a descrivere l'andamento dei mercati globali, penalizzando i modelli a elevata capacità espressiva.




Figura 7: Confronto dell'accuratezza sul Test Set in base allo spazio di feature d'ingresso (Senza Riduzione, Spazio PCA 4D, Spazio FDA 1D).

Infine, per comprendere le differenze sistematiche tra l'approccio geometrico delle SVM e quello probabilistico dell'MLP, si analizza la Figura 8, che mette a confronto le matrici di confusione dei due modelli sul Test Set nello spazio latente PCA.




Figura 8: Matrici di confusione sul Test Set nello spazio PCA: SVM (sinistra) ed MLP (destra).

La mappa degli errori evidenzia come l'MLP (a destra) presenti un comportamento leggermente più bilanciato ed efficiente rispetto alla SVM (a sinistra):

- **Classe positiva (Rialzo, 1):** L'MLP ottiene **82 Veri Positivi** (contro gli 88 della SVM), commettendo **17 Falsi Negativi** (contro gli 11 della SVM).
- **Classe negativa (Ribasso, 0):** Al contrario, l'MLP riesce a catturare in modo molto più efficace le contrazioni del mercato turco, registrando ben **43 Veri Negativi** (contro i soli 36 della SVM) e limitando i **Falsi Positivi a soli 19** (contro i 26 della SVM).

Questo bilanciamento porta l'MLP a raggiungere un F_1 -score globale superiore, confermandosi come il modello predittivo più robusto per l'analisi del dataset finanziario in esame.

4 Conclusioni e Sviluppi Futuri

In questo capitolo finale viene tracciato un bilancio critico e analitico dell'intero percorso sperimentale e teorico condotto sul dataset finanziario dell'Istanbul Stock Exchange. L'obiettivo dell'elaborato è stato quello di valutare l'efficacia di diversi paradigmi di apprendimento automatico — di natura generativa, discriminativa, non parametrica e gerarchica — nella risoluzione di un problema di classificazione binaria applicato alle serie storiche dei rendimenti azionari. L'intero flusso di lavoro è stato strutturato ponendo un accento rigoroso sul pre-processing protetto, sulla riduzione dimensionale ottimale e sulla prevenzione metodologica di fenomeni di contaminazione dei dati, conformemente alle lezioni della teoria dell'apprendimento statistico.

4.1 Sintesi Comparativa dei Risultati Empirici

La sperimentazione condotta ha permesso di evidenziare dinamiche di estremo rilievo circa l'interazione tra la geometria dello spazio delle caratteristiche e la capacità espressiva dei singoli classificatori. I risultati di accuratezza misurati sul Test Set (non preso in esame durante la fase di addestramento) mostrano andamenti fortemente diversificati in base allo spazio proiettivo di partenza, come mostrato nel grafico a barre riepilogativo (Figura 7):

- **Spazio Originale standardizzato (7D):** In questa configurazione, il classificatore non parametrico k -NN ha registrato un'accuratezza del **73.91%** per $k = 5$, mentre la Linear Discriminant Analysis (LDA) si è attestata al **72.05%** e la Support Vector Machine Kernel RBF ha raggiunto il **75.16%**. Al contrario, la rete neurale Multi-Layer Perceptron (MLP) ha mostrato vistosi limiti di generalizzazione, fermandosi a un'accuratezza del **67.70%**. Questo comportamento dell'MLP evidenzia il classico fenomeno di Hughes, o sovra-parametrizzazione: la presenza di collinearità marcate tra le features (in particolare tra gli indici europei DAX, FTSE ed EU, che superano correlazioni di 0.90 nella heatmap di Pearson) e di rumore finanziario ad alta frequenza ha indotto la rete ad adattarsi eccessivamente alle fluttuazioni spurie del Training Set, fallendo nella convergenza verso un ottimo globale di generalizzazione.
- **Spazio Latente Ridotto tramite PCA (4D):** La proiezione dei dati sulle prime quattro componenti principali (in grado di preservare il **95.4%** della varianza cumulativa totale) ha generato l'effetto metodologico più interessante dell'intero studio. Mentre il k -NN ha subito una lieve flessione fisiologica (**72.67%**) dovuta alla perdita del 4.6% di informazione originale, sia l'LDA che la rete MLP hanno registrato elevati incrementi di accuratezza, salendo rispettivamente al **75.16%** e al **77.64%** (performance assoluta della sperimentazione). Questo risultato rappresenta una rilevante conferma della teoria algebrica: la PCA, estraendo componenti latenti tra loro ortonormali, ha rimosso completamente la multicollinearità delle variabili d'ingresso. L'esclusione della ridondanza informativa ha agito come un regolarizzatore spaziale, risanando il condizionamento numerico della matrice di covarianza dell'LDA e semplificando drasticamente il costo della rete neurale, che ha potuto così convergere verso un ottimo di generalizzazione stabile.
- **Spazio Ridotto Supervisionato tramite FDA (1D):** La compressione dello spazio a una sola coordinata proiettiva (limite teorico imposto dalla classificazione binaria $c - 1 = 1$) ha evidenziato un dimezzamento delle prestazioni per i classificatori a elevata capacità espressiva, con la rete MLP e la Kernel SVM che arretrano rispettivamente al **72.67%** e al **74.53%**. Ciò dimostra che la frontiera decisionale che separa i rendimenti positivi e negativi della borsa di Istanbul possiede una complessità intrinseca non lineare che non può essere preservata all'interno di un'unica proiezione lineare unidimensionale, confermando la necessità di disporre di spazi latenti a dimensionalità intermedia ($k = 4$).

4.2 Verifiche delle Equivalenze Algebriche e Rigore Teorico

La sperimentazione ha fornito una solida conferma empirica dei teoremi studiati a lezione. Si osservi, infatti, che il valore di accuratezza ottenuto dal classificatore probabilistico LDA sullo spazio originale a 7 dimensioni (**72.05%**) coincide in modo preciso con il valore misurato sullo spazio ridotto a 1 dimensionale della FDA (**72.05%**).

Questa uguaglianza numerica non costituisce una coincidenza fortuita, bensì rappresenta la dimostrazione pratica del teorema di equivalenza tra l'analisi discriminante lineare e il discriminante di Fisher.

Sotto l'ipotesi di omoschedasticità (matrici di covarianza identiche tra le classi) e di normalità multi-variata dei dati, lo spazio proiettivo ottimale calcolato dalla FDA per massimizzare il rapporto tra la varianza inter-classe e la varianza intra-classe coincide esattamente con la direzione del vettore normale all'iperpiano di decisione calcolato dalla LDA Bayesiana, a meno di un fattore di scala costante. Di conseguenza, classificare i dati nello spazio originario a 7 dimensioni mediante l'iperpiano dell'LDA equivale algebricamente a proiettare i punti sulla retta della FDA e assegnare la classe in base alla distanza minima dal centroide proiettato.

4.3 Analisi Geometrica e Macroeconomica dell'Asimmetria delle Predizioni

Sebbene il dataset sia stato bilanciato quantitativamente all'origine binarizzando il target ISE attorno allo zero (Classe 1 per ISE positivo, Classe 0 per ISE negativo o nullo), si osserva una vistosa e sistematica asimmetria qualitativa nelle capacità predittive di tutti i modelli addestrati. La Kernel SVM ottimizzata tramite Grid Search (Figura 6) mostra una Recall dell' **82.83%** sulla classe positiva (Rialzo), ma sperimenta una drastica caduta della sensibilità sulla classe negativa (Ribasso), registrando una Recall del **64.52%** a causa di 22 Falsi Positivi su un totale di 62 campioni di ribasso reali nel Test Set.

La spiegazione di questo fenomeno richiede una combinazione di considerazioni geometriche e macroeconomiche:

- **Dinamica del Rialzo (Classe 1):** Durante i periodi di espansione economica globale, i mercati finanziari internazionali mostrano movimenti rialzisti fortemente coesi e sincronizzati (effetto di integrazione globale). Gli indici esteri standardizzati (S&P 500, DAX, FTSE, EU) forniscono un segnale forte, coerente e ad alto rapporto segnale-rumore, che i classificatori riescono a mappare con estrema facilità. Nello spazio latente della PCA, i punti di rialzo tendono a condensarsi in un cluster geometricamente denso e ben orientato lungo le direzioni delle prime componenti.
- **Dinamica del Ribasso (Classe 0):** Al contrario, le improvvise correzioni giornaliere e i ribassi minori della borsa turca (ISE) sono spesso governati da fattori politici interni, dinamiche monetarie locali o shock geopolitici idiosincratici della Turchia. Tali eventi locali non presentano alcuna correlazione con l'andamento degli indici delle borse estere occidentali. Geometricamente, le giornate di ribasso si distribuiscono nello spazio latente con un'elevata entropia, disperdendosi in modo disordinato all'interno del cluster positivo e generando una compenetrazione visibile nello scatter plot 3D della PCA (Figura 3). La presenza di questa compenetrazione geometrica rende impossibile tracciare un confine di separazione netto, giustificando la presenza dei Falsi Positivi.

4.4 Violazione dell'Ipotesi I.I.D. e Limitazioni dei Modelli Spaziali

Sotto il profilo della teoria dell'apprendimento statistico (PAC Learning), un'assunzione teorica fondamentale per la validità dei limiti superiori al rischio di generalizzazione (Sample Complexity Bounds basati sulle disuguaglianze di concentrazione di Hoeffding o di McDiarmid) prevede che i campioni del Training Set e del Test Set siano estratti in modo indipendente e identicamente distribuito (*i.i.d.*) da una distribuzione di probabilità congiunta globale D :

$$S = (z_1, z_2, \dots, z_m) \sim D^m \quad (65)$$

Tuttavia, le serie storiche dei rendimenti azionari non soddisfano pienamente l'ipotesi di indipendenza. Nei dati finanziari sono infatti presenti fenomeni come l'autocorrelazione dei rendimenti e il 'volatility clustering', in cui periodi ad alta volatilità tendono a raggrupparsi nel tempo. L'applicazione di modelli "spaziali" o statici (come LDA, k -NN, SVM e MLP), che trattano ciascun giorno operativo come un'osservazione isolata e indipendente ignorando l'ordine cronologico dei dati, rappresenta una severa limitazione metodologica. Questa sfasatura tra le assunzioni matematiche dei modelli e la reale natura temporale dei dati finanziari comporta che i tassi di accuratezza misurati, per quanto validati in modo protetto tramite pipeline, possano risentire di una parziale instabilità nel lungo periodo.

4.5 Sviluppi Futuri

Al fine di superare le limitazioni riscontrate e migliorare ulteriormente la robustezza e la precisione delle predizioni, si delineano le seguenti prospettive di ricerca e sviluppo futuro:

1. **Modelli Sequenziali e Architetture Deep Temporal:** Risulta prioritario abbandonare l'approccio statico a favore di modelli in grado di catturare esplicitamente le dipendenze temporali. In quest'ottica, l'impiego di modelli che perservano la volatilità variabile nel tempo e di reti che catturano esplicitamente la dipendenza temporale sequenziale, consentirebbe di stimare preventivamente la volatilità giornaliera del mercato turco e di elaborare i rendimenti come sequenze ordinate, memorizzando la storia passata del mercato per predire le transizioni future.
2. **Ingegnerizzazione di Caratteristiche Locali:** Per risolvere il problema dell'elevata quota di Falsi Positivi dovuti alla cecità dei mercati esteri rispetto ai rischi locali della Turchia, è fondamentale arricchire il dataset inserendo variabili macroeconomiche interne del paese. L'inclusione di tassi d'interesse della borsa di Istanbul, dell'inflazione mensile turca, del tasso di cambio Lira/Dollaro e degli spread sui Credit Default Swaps (CDS) turchi consentirebbe di mappare accuratamente anche i ribassi guidati da fattori interni.